

Princípios de Tratamento e Manuseio de Dados

Marcelo Ventura Freire (EACH/USP)

Contents

Princípios de Tratamento e Manuseio de Dados	1
Conjuntos de Dados	1
Organizando um Conjunto de Dados	5
Programe! Não faça manualmente!	16
Boas Práticas	18
Integrando Conjuntos de Dados	22

Princípios de Tratamento e Manuseio de Dados

Princípios

Objetivo

Organizar o conjunto de dados para que possa ser analisado estatisticamente

1. Conjuntos de Dados
2. Organizando um Conjunto de Dados
3. Programe! Não Faça Manualmente
4. Boas Práticas
5. Integração de Dois ou Mais Conjuntos de Dados

Conjuntos de Dados

Conjuntos de Dados

Conceitos

- Observação
- Variável
- Metainformação
- Conjunto de dados estruturado
- Conjunto de dados não estruturado

Conjuntos de Dados

Observação

- Unidade provedora de informação individual
- Pode ser
 - uma pessoa
 - uma tentativa de execução de uma tarefa
 - uma realização de um teste

Conjuntos de Dados

Observação

A escolha adequada depende do contexto do *seu* problema.

Um exemplo:

20 participantes são divididos em um grupo de controle e um grupo de tratamento, cada um com 10 participantes.

Serão administrados um comprimido com uma dosagem de cafeína aos participantes do grupo de tratamento e um comprimido inerte aos participantes do grupo controle.

Conjuntos de Dados

Observação

Se registrarmos uma medida de atenção apenas após a administração do comprimido

- uma observação será a resposta de cada participante
 - simples assim

Conjuntos de Dados

Observação

Se registrarmos uma medida de atenção *antes* e uma *depois* a administração do comprimido

- uma observação poderá ser a resposta de cada participante
 - em cada observação: uma medição *pré-intervenção* e uma medição *pós-intervenção*
 - cada participante gerará uma única observação
- uma observação poderá ser a resposta de cada participante em cada condição
 - em cada observação: uma condição de medição (*pré* ou *pós*) e a medição sob essa condição
 - cada participante gerará duas observações

Conjuntos de Dados

Observação

Qual é a melhor escolha?

- Depende do que você vai precisar fazer com os dados
 - em algumas situações, a primeira forma será mais adequada
 - em outras situações, a segunda forma será mais adequada
 - em outras situações ainda, ora será uma, ora será outra
 - * conversão entre formatos
 - mais adiante

Conjuntos de Dados

Variável

- Atributos ou características de interesse nas observações
 - o que é *característica* do indivíduo é *variável* na população
- Podem ser *primárias* ou *derivadas*
 - Primárias: peso, estatura
 - * Derivada: IMC
 - Primárias: latitude e longitude
 - * Derivada: fuso horário oficial

Conjuntos de Dados

Variável

- Podem ser *quantitativas* ou *qualitativas*
 - Quantitativas: valores numéricos
 - * contínuas: resultados de medições
 - * discretas: resultados de contagens
 - Qualitativas (ou *Catégoricas*): *níveis* ou *categorias*
 - * ordinais: com uma ordem entre as categorias
 - * nominais: sem uma ordem ou com ordem ignorável
 - É possível a conversão entre esses tipos:
 - * Contínua > Discreta > Ordinal > Nominal

Conjuntos de Dados

Variável

Exemplos

- estatura, peso e IMC

- pressões sistólica e diastólica
- estado civil
- condição em relação a um alelo específico:
 - homozigoto *vs* heterozigoto
 - dominante *vs* recessivo
 - homozig. dominante *vs* heterozig. *vs* homozig. recessivo

Conjuntos de Dados

Metainformação

“Informação sobre a informação”

- Na verdade, informação sobre as variáveis
 - nome longo da variável
 - tipo: contínua, discreta, ordinal, nominal
 - para variáveis qualitativa:
 - * quantos e quais são as categorias possíveis
 - * nome longo para as categorias
 - para as ordinais: ordem entre as categorias
 - para variáveis derivadas: relação com as outras variáveis
 - * $IMC = \frac{peso}{estatura^2} \Leftrightarrow IMC = peso/estatura^2$

Conjuntos de Dados

Conjunto de Dados Estruturado

- *Linha = Observação*
- Todas as linhas contêm os valores das mesmas variáveis e na mesma sequência
- O conjunto de dados contém metainformações

Conjuntos de Dados

Conjunto de Dados Estruturado

Linha = Observação

- cada linha contém os dados de uma única observação
- os dados de uma mesma observação estão todos em uma única linha

Conjuntos de Dados

Conjunto de dados estruturado

Todas as linhas contêm os valores das mesmas variáveis e na mesma sequência

Nome: João; Sobre: Silva; Idade: 23; Estat: 1,67 m; EstCiv: Solteiro
 Nome: Maria; Sobre: Alves; Idade: 32; Estat: 1,63 m; EstCiv: Casado

é o mesmo que

Nome	Sobre	Idade	Estat	EstCiv
João	Silva	23	1,67	Solteiro
Maria	Alves	32	1,63	Casado

Conjuntos de Dados

Conjunto de Dados Estruturado

O conjunto de dados contém as metainformações referentes aos dados

```
Sobre: "Sobrenome"
NomeInt = Nome + Sobre
EstCiv: "Estado Civil"
EstCiv: {Solteiro, Casado, UniaoEstavel, Divorciado, Desquitado, Viuvo}
Idade: "Idade em anos Completos"
Idade: "%3d"
Idade: [0, 150]
Estatura: "Estatura em metros com até a segunda casa decimal"
Estatura: "%4.2f"
Estatura: (0, 3)
```

Conjuntos de Dados

Conjunto de Dados Não Estruturado

- Cada linha pode conter os dados de mais do que uma observação
- Os dados de uma mesma observação pode aparecer em mais de uma linha
- Nem todas as variáveis estão presentes em todas as observações
- As observações podem ter mais de um valor para a mesma variável
- As variáveis podem aparecer em qualquer ordem
- O conjunto de dados pode não conter metainformações

Organizando um Conjunto de Dados

Organizando um Conjunto de Dados

1. Importação a partir de um arquivo criado por outros programas
2. Crítica dos dados
3. Formato do conjunto de dados
4. Transformações de variáveis

Importação dos Dados

Origens possíveis para os dados

- Excel
- Google Forms

- Coleta biométrica de dados (e.g., sensores, actímetro, *eye tracking* etc.)
- Dados armazenados em arquivos de outros programas estatísticos (SPSS, Stata, Minitab, SAS etc.)
- Dados oriundos de sistemas de gerenciamento de bancos de dados (SGBD), extraídos via, e.g., SQL
- Dados não estruturados coletados eletronicamente (e.g., *log* das buscas realizadas no Google em um intervalo de uma hora)

Importação dos Dados

Problemas que podem ocorrer na importação dos dados

- mais de um *encoding* utilizado no conjunto de arquivos a serem importados
 - ASCII puro
 - ISO 8859, ISO 8859-1, ISO 8859-15 (padrões do Windows no ocidente)
 - Unicode (ISO 10646), UTF-32, UTF-16, UTF-8 (padrão web atual)
- várias abas dentro da mesma planilha do Excel
- formato de arquivo desconhecido
- arquivos corrompidos

Crítica dos Dados

Deteção e correção de potenciais erros de digitação, transcrição e manuseio, bem como orientação para realização das correções

"Shit happens" (Confúcio)
 "... all the time" (Lao Tse)

1. Padrões de erros
2. Valores não razoáveis
3. Valores discrepantes (*outliers*)
4. Uso inconsistente dos nomes de categorias
5. Inconsistências
6. Listagem de valores a serem verificados

Crítica dos Dados

Padrões de Erros

Começou em uma linha e passou para a próxima sem perceber

##	A	B	C	D	E	F
## 1	1	10	0.23	A	masc	125
## 2	2	12	0.57	B	fem	200
## 3	1	11	0.62			
## 4				B	fem	400
## 5	4	13	0.72	A	fem	300

Crítica dos Dados

Padrões de Erros

Pulou uma coluna, deixou em branco e continuou na seguinte

```
##      A      B      C      D      E      F      G
## 1    1    10 0.23      A masc 125
## 2    2    12 0.57      B fem  200
## 3    1          11 0.62      B fem 400
## 4    4    13 0.72      A fem  300
```

Crítica dos Dados

Padrões de Erros

Digitou sobre uma célula já preenchida ou pulou um valor

```
##      A      B      C      D      E      F
## 1    1    10 0.23      A masc 125
## 2    2    12 0.57      B fem  200
## 3    1 0.62      B fem  400
## 4    4    13 0.72      A fem  300
```

Crítica dos Dados

Valores Não Razoáveis

Muitas variáveis quantitativas têm intervalos de valores possíveis claramente definidos.

Valores fora desses intervalos são suspeitos e devem ser confirmados individualmente.

Exemplo: idade superior a 100 anos


- não é necessariamente um erro
- mas é raro

Crítica dos Dados

Valores Discrepantes

Queria ter digitado 12.34, mas digitou 124

```
tempo <- c(12.36, 12.42, 124, 11.99, 10.77, 11.05, 13.20)
boxplot(tempo, horizontal = T)
```



Crítica dos Dados

Uso inconsistente dos nomes de categorias

Mais de um rótulo para a mesma categoria

```
##   Sexo Estádio Hodgkin Benigno
## 1   M         2     não     Ben
## 2 Masc       II      n      sim
## 3   F     Est1    nao      B
## 4   f       1A      0      s
```

Crítica dos Dados

Inconsistências

Os valores individuais das variáveis podem não ser suspeitos, mas a sua combinação pode ser

- Participante com 12 anos de idade e com 40 anos de instrução
- A soma de horas das atividades realizadas em um dia superam 24h
- Etc.

Crítica dos Dados

Listagem de Valores a Serem Verificados

Algumas vezes, esses erros podem ser corrigidos na fase de importação e crítica, mas, na maioria da vezes, não.

Por isso, é útil gerar uma listagem individualizando quais observações precisam de confirmação (e em quais variáveis) e redigitação caso seja constatado erro.

Crítica dos Dados

Listagem de Valores a Serem Verificados

Em algumas vezes, pode ser útil que essa listagem seja gerada duas vezes:

- uma listagem ordenada por observação (útil para o verificador)
- uma listagem ordenada por variável (útil para o programador)

Crítica dos Dados

“Para saber mais, clique em ...”

“Ok, fiquei interessado pelo assunto de crítica e limpeza de dados.”

“Onde posso encontrar mais sobre o assunto?”

Crítica dos Dados

“Para saber mais, clique em ...”

Google! (*Id est*, te vira, negão!)

Mas com os termos certos.

- “Data Cleaning”
- “Data Cleansing”
- “Data Scrubbing”
- “Data Design”
- entre outros

Crítica dos Dados

“Para saber mais, clique em ...”

Devido ao crescimento do interesse por *Big Data* e por *Quantitative Analytics* em geral, hoje em dia também há muita literatura interessante sobre o assunto fora da Estatística e dentro da Computação em geral.

Crítica dos Dados

“Para saber mais, clique em ...”

Por exemplo, é possível encontrar isto ...

Crítica dos Dados

“Para saber mais, clique em ...”

ou isto.

Formato do Conjunto de Dados

Adequação do formato do conjunto de dados ao uso pretendido

1. Formato largo *vs* formato longo
2. Conversão de conjunto de dados de um formato para o outro

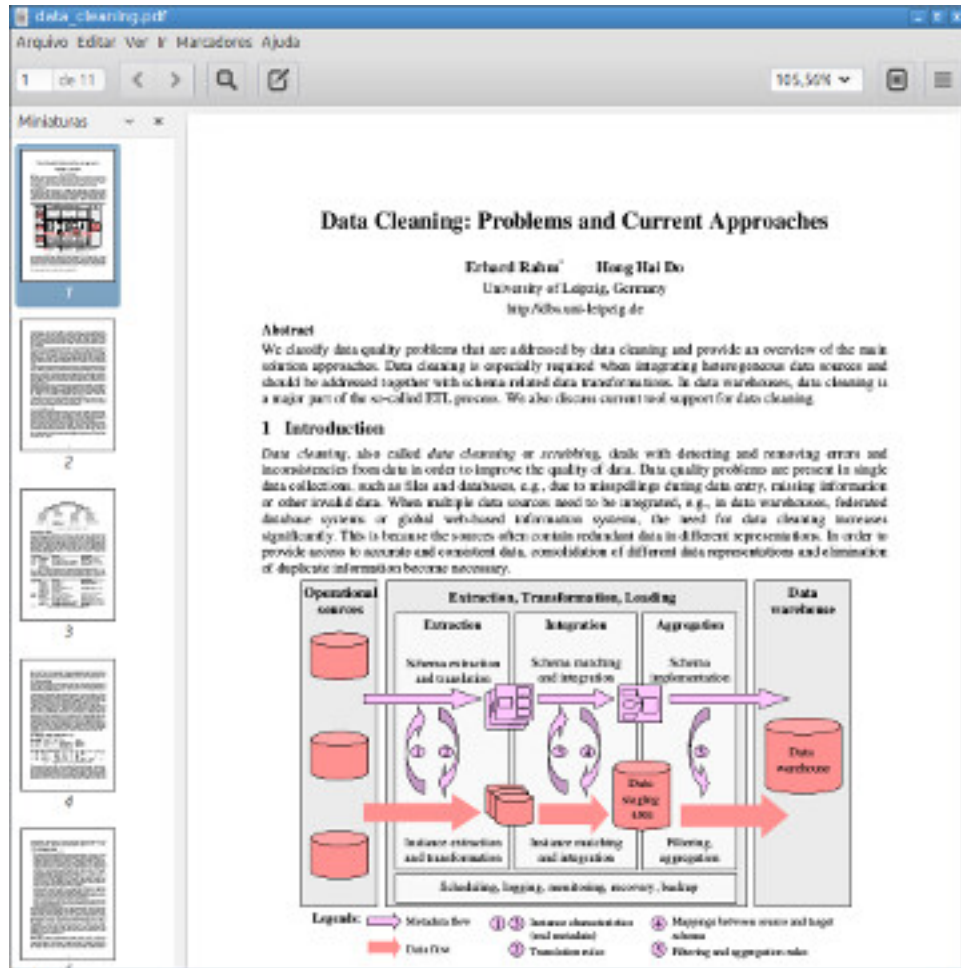


Figure 1: http://betterevaluation.org/sites/default/files/data_cleaning.pdf

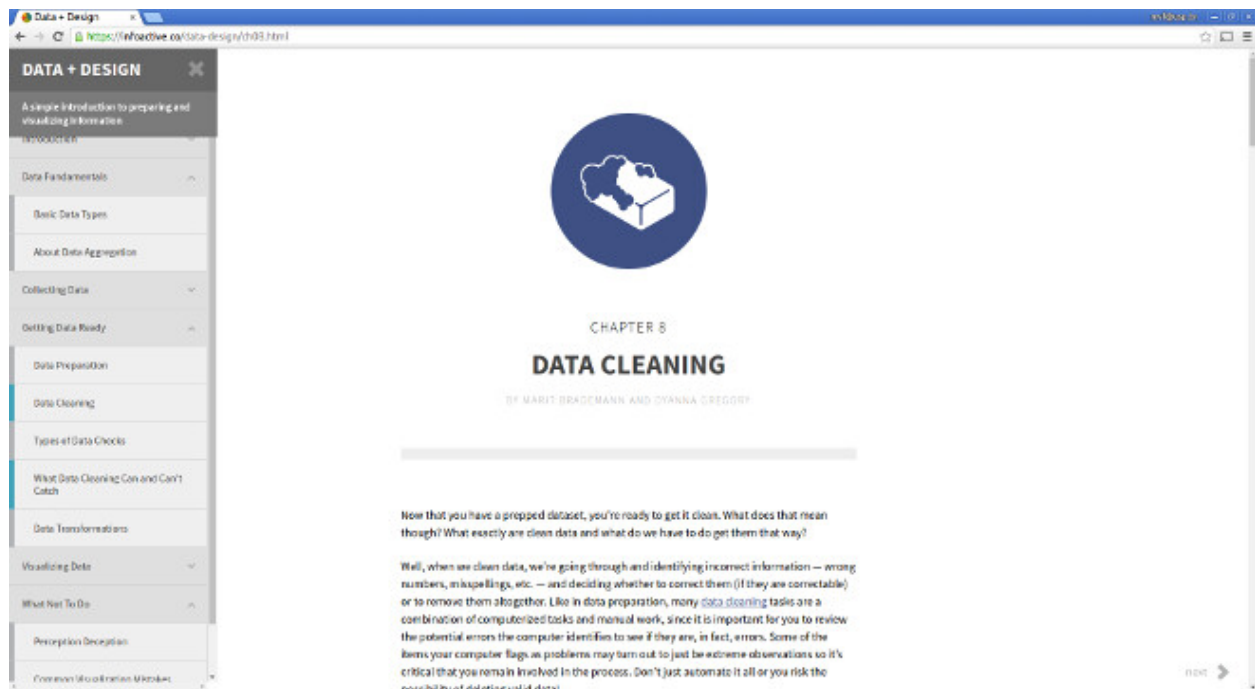


Figure 2: <https://infoactive.co/data-design/ch08.html>

Formato do Conjunto de Dados

Formato Largo (*Wide*)

Algumas funções que implementam técnicas estatísticas (*e.g.*, análise de variância com medidas repetidas) exigem os dados neste formato ...

```
##   suj dilat.t0 dilat.t1
## 1   1       2.1      2.3
## 2   2       1.7      1.9
## 3   3       2.1      2.5
```

Formato do Conjunto de Dados

Formato Longo (*Long*)

... já outras exigem os dados neste formato (*e.g.*, funções para gerar gráficos e visualizações)

```
##   suj tempo dilat
## 1   1     0    2.1
## 2   1     1    2.3
## 3   2     0    1.7
## 4   2     1    1.9
## 5   3     0    2.1
## 6   3     1    2.5
```

Formato do Conjunto de Dados

Conversão de um formato para o outro conforme a necessidade

```
##    suj dilat.t0 dilat.t1
## 1    1      2.1      2.3
## 2    2      1.7      1.9
## 3    3      2.1      2.5
```

```
##    suj tempo dilat
## 1    1     0  2.1
## 2    1     1  2.3
## 3    2     0  1.7
## 4    2     1  1.9
## 5    3     0  2.1
## 6    3     1  2.5
```

Transformação de Variáveis

1. Dado Quantitativo → Dado Quantitativo
2. Dado Quantitativo → Dado Qualitativo
3. Dado Qualitativo → Dado Qualitativo
4. Dado Textual → Dado Qualitativo/Quantitativo

Transformação de Variáveis

Dado Quantitativo → Dado Quantitativo

Arredondamento

```
tempos <- c(314.326, 42.597, 0.817, 7.914, 197.314, 12.480)
round(tempos, 1)
```

```
## [1] 314.3 42.6 0.8 7.9 197.3 12.5
```

```
round(tempos)
```


```
## [1] 314 43 1 8 197 12
```

Transformação de Variáveis

Dado Quantitativo → Dado Quantitativo

Reexpressão em outras escalas

```
boxplot(tempos, horizontal = T)
```




Transformação de Variáveis

Dado Quantitativo → Dado Quantitativo

Reexpressão em outras escalas

```
boxplot(log(tempos), horizontal = T)
```



Transformação de Variáveis

Dado Quantitativo → Dado Qualitativo

Categorização

```
idades <- c(8, 12, 17, 21, 25, 40, 80)
cortes <- c(0, 12, 17, 59, Inf)
categs <- c("criança", "adolescente", "adulto", "idoso")
data.frame(idade = idades,
           faixa.etária = cut(idades, breaks = cortes, labels = categs))
```

```
##   idade faixa.etária
## 1     8   criança
## 2    12   criança
## 3    17 adolescente
## 4    21   adulto
## 5    25   adulto
## 6    40   adulto
## 7    80    idoso
```

Transformação de Variáveis

Dado Qualitativo → Dado Qualitativo

Junções de categorias

```
cortes2 <- c(0, 17, Inf)
categs2 <- c("menor", "maior")
data.frame(idade = idades,
  faixa.etária = cut(idades, breaks = cortes, labels = categs),
  status.legal = cut(idades, breaks = cortes2, labels = categs2))
```

```
##   idade faixa.etária status.legal
## 1     8     criança     menor
## 2    12     criança     menor
## 3    17 adolescente     menor
## 4    21      adulto     maior
## 5    25      adulto     maior
## 6    40      adulto     maior
## 7    80       idoso     maior
```

Transformação de Variáveis

Dado Qualitativo → Dado Qualitativo

Renomeando categorias

```
categs3 <- c("F1", "F2", "F3", "F4")
data.frame(
  idade = idades,
  faixa.etária = cut(idades, breaks = cortes, labels = categs),
  faixa = cut(idades, breaks = cortes, labels = categs3))
```

```
##   idade faixa.etária faixa
## 1     8     criança  F1
## 2    12     criança  F1
## 3    17 adolescente  F2
## 4    21      adulto  F3
## 5    25      adulto  F3
## 6    40      adulto  F3
## 7    80       idoso  F4
```

Transformação de Variáveis

Dado Textual → Dado Qualitativo/Quantitativo

1. Filtragem de texto
2. Identificação de presença de padrão
3. Transformação de texto

Transformação de Variáveis

Dado Textual → Dado Qualitativo/Quantitativo

Na verdade, uma área inteira de análise de dados é baseada nessa ideia: a análise estatística de um *corpus* textual.

O que veremos aqui não tem a pretensão de ser uma introdução aos conjuntos de técnicas dessa área, mas simplesmente ser uma apresentação ao problema em si.

Se a complexidade do problema estiver muito grande, procure se aconselhar com alguém que já tenha lidado com isso antes.

Transformação de Variáveis

Dado Textual → Dado Qualitativo/Quantitativo

Sugestão

Se você tem pouca experiência:

- Passe essa atividade para alguém que já saiba fazer isso
- OU
- Reserve um bocado de tempo para aprender a fazer isso direito.

Transformação de Variáveis

Dado Textual

Filtragem de texto

```
nomes <- c("Marcos", "marcos", "Pedro", "pEDRO", "maRcoS", "MARCOS")
data.frame(Nome = nomes, seq = seq(nomes))
```

```
##      Nome seq
## 1 Marcos   1
## 2 marcos   2
## 3 Pedro    3
## 4 pEDRO    4
## 5 maRcoS   5
## 6 MARCOS   6
```

Transformação de Variáveis

Dado Textual

Filtragem de texto

```
filtro <- tolower(nomes) == "marcos"
data.frame(Nome = nomes, seq = seq(nomes))[filtro, ]
```

```
##      Nome seq
## 1 Marcos   1
## 2 marcos   2
## 5 maRcoS   5
## 6 MARCOS   6
```

```
filtro
```

```
## [1] TRUE TRUE FALSE FALSE TRUE TRUE
```

Transformação de Variáveis

Dado Textual

Identificação de presença de padrão

```
comentário <- c("gostei", "não gosto", "agosto", "odiei Gião")
data.frame(o.que.disse = comentário,
           referência.ao.verbo.gostar = grepl("(^[ ])gost[ ]+", comentário))
```

```
##      o.que.disse referência.ao.verbo.gostar
## 1      gostei                      TRUE
## 2    não gosto                      TRUE
## 3      agosto                     FALSE
## 4    odiei Gião                     FALSE
```

Transformação de Variáveis

Dado Textual

Transformação de texto

```
nome <- c("Márcia", "Mârcia", "Marcia", "Marcia")
data.frame(Nome = nome, nome = iconv(nome, to = "ASCII//TRANSLIT"))
```

```
##      Nome  nome
## 1 Márcia Marcia
## 2 Mârcia Marcia
## 3 Marcia Marcia
## 4 Marcia Marcia
```

Programe! Não faça manualmente!

Programe! Não faça manualmente!

Processamento manual dos dados

- Erros sistemáticos

- Difíceis de detectar e de localizar

Processamento dos dados através de programação

- Erros sistemáticos
 - Mais fáceis de detectar e de localizar

Programa! Não faça manualmente!

Por que programar se posso fazer na unha?

1. Rastreabilidade
 - “Esses dados estão certos?”
 - Você mesmo, após seis meses sem mexer nos dados
2. Documentação
 - “O quê é que são esses dados mesmo?”
 - *Idem, ibidem*
3. Reaproveitabilidade de esforço e de código
 - Lavoisier: “Nada se cria e nada se perde: tudo se aproveita.”

Boas Práticas

Boas Práticas



Boas Práticas

1. Não jogue fora o original
2. Porque é tão fácil bagunçar um conjunto de dados no Excel
3. Variáveis primárias *vs* variáveis derivadas
4. **Vetorização**

Boas Práticas

Não jogue fora o original

É sério: é muito comum mexer no arquivo original dos dados, perceber que alguma ~~caçada~~ besteira foi feita e não haver uma cópia do original.

Por isso, antes de começar a mexer nos dados, **crie uma cópia do arquivo de dados original e deixe-a fora da pasta de trabalho**, a salvo dos seus dedinhos.

- Depois não diga que eu não avisei.

Boas Práticas

Porque é tão fácil bagunçar um conjunto de dados no Excel

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19
1	paciente	sexo	idade	data-entrada	data-saida	data-seguinte	peso	altura	PC	AR	GRADIENTE	PC	AR	GRADIENTE	PC	AR	GRADIENTE	
2	1	M	25	0	0	0	82	1,75m	68	44	155	54	35,2	154,8	85	42,24	155,76	Medioplano
3	2	M	22	1	0	0	70	1,60m	58	35	72	48	39	57,8	55	33,4	86,12	Detalado
4	3	F	60	0	1	0	75	1,6m	56	54	60	45	45,2	48	54	51,84	57,8	IECA
5	4	M	53	0	1	0	51	1,55m	40	28	50	50	22,4	40	40	26,88	48	IECA, Amiodarona
6	5	F	67	1	0	0	69	1,77	78	43	68	62	34,4	54,4	74	41,28	65,28	Vasopressor
7	6	M	63	0	0	0	75	1,65	60	48	85	64	30,2	48	77	47,04	81,6	Vasopressor
8	7	F	57	0	1	0	122	1,52	70	38	96	96	30,4	79,2	87	36,48	95,04	IECA, Amiodarona
9	8	M	52	0	1	0	75	1,45	60	50	81	64	43	54,8	77	48	77,76	Amiodarona
10	9	M	71	1	0	0	90	1,72	80	38	70	64	30,4	56	77	36,48	67,2	DB
11	10	F	69	0	0	0	62	1,7m	61	30	101	48	31,2	144,8	50	37,44	170,76	Amiodarona, BB
12	11	M	69	0	1	0	nc	nc	62	42	86	90	33,6	52,8	80	40,32	63,36	Detalado
13	12	F	58	1	0	0	nc	nc	66	47	107	53	37,6	85,6	64	45,12	102,72	Detalado
14	13	M	68	1	0	0	80	1,65	70	48	130	96	36,4	108	87	46,08	128,8	IECA
15	14	F	63	0	0	0	nc	nc	68	48	95	70	30,2	76	84	47,04	81,2	IECA, Amiodarona
16	15	M	45	1	0	0	64	1,54	100	50	30	80	28,8	40	86	34,08	48	Vasopressor
17	16	M	56	0	1	0	130	1,75	51	50	85	41	42	52	49	42	62,4	Vasopressor
18	17	F	48	0	1	0	64	1,57	60	30	100	32	44	37,2	82	32,8	104,64	IECA, Amiodarona
19	18	M	48	1	0	0	nc	nc	50	43	99	48	34,4	79,2	55	41,28	95,04	Amiodarona
20	19	F	39	0	0	0	40	1,54	72	30	130	98	28	110,4	70	33,8	132,48	DB
21	20	M	60	0	1	0	73	1,7	55	41	140	44	32,6	114,4	53	39,36	127,20	Amiodarona, BB
22	21	F	44	0	1	0	62	1,77	63	48	70	68	30,4	80	79	40,08	72	Vasopressor
23	22	M	61	1	0	0	nc	nc	59	43	24	47	34,4	19,2	50	41,28	23,04	IECA, Amiodarona
24	23	M	48	0	0	0	65	1,65	56	39	140	16	31,2	112	86	37,44	134,4	Amiodarona
25	24	F	63	0	1	0	80	1,65	68	47	78	70	37,6	62,4	84	43,12	74,88	DB
26	25	M	30	1	0	0	63	1,68	70	40	71	38	39	39,0	87	43,2	98,16	Amiodarona, BB
27	26	F	53	1	0	0	69	1,71	70	40	70	60	32	80	72	36,4	72	Detalado
28	27	M	70	0	0	0	45	1,7	60	40	101	38	32	80,0	43	82,4	86,96	Detalado
29	28	F	57	1	0	0	80	1,75	60	28	124	48	22,4	99,2	50	26,88	119,04	IECA
30	29	M	57	0	1	0	64	1,7	57	48	37	48	30,0	29,0	50	44,16	35,52	IECA, Amiodarona
31	30	M	69	0	1	0	73	1,63m	68	40	160	48	32	132	50	36,4	158,4	Detalado
32	31	F	45	1	0	0	68	1,64	70	42	85	60	33,6	88	72	43,32	81,6	Detalado
33	32	M	50	0	0	0	71	1,63	57	37	120	48	40,6	100	50	34,72	120	IECA
34	33	F	60	0	1	0	74	1,62	67	48	104	54	36,6	87,2	65	44,16	104,64	IECA, Amiodarona
35	34	M	33	0	1	0	73	1,68	52	44	85	42	35,2	88	50	42,24	81,6	Vasopressor
36	35	F	48	1	0	0	63	1,55	58	60	110	48	49	86	55	37,8	105,8	Vasopressor
37	36	M	57	0	0	0	62	1,4	60	59	76	72	47,2	80,8	86	36,64	72,96	IECA, Amiodarona
38	37	M	57	0	1	0	85	1,65	71	47	74	57	37,6	59,2	66	45,12	71,04	Amiodarona
39	38	F	44	1	0	0	83	1,66	34	47	74	59	37,6	59,2	71	45,12	71,04	DB
40	39	M	44	1	0	0	82	1,71	68	48	126	54	36,6	102,6	65	46,08	122,88	Amiodarona, BB
41	40	F	54	0	0	0	70	1,4	82	45	58	98	34	46,4	79	43,2	56,96	Detalado
42	41	media	54,77				78,12	8,07	68,44	45,99	93,58	54,78	36,00	74,86	65,64	43,20	89,83	
43	42	des	19,75				13,88	33,96	12,28	7,84	18,81	9,77	6,28	28,48	11,76	7,83	34,18	
44	43	SEXO																
45	44	F=Feminino																
46	45	M=Masculino																
47	46																	
48	47																	
49	48																	
50	49																	
51	50																	

Figure 3:

Boas Práticas

Porque é tão fácil bagunçar um conjunto de dados no Excel

- O conceito de planilha eletrônica foi desenvolvido para armazenar dados não estruturados.
- Ela pode ser usada para armazenar dados estruturados, mas ela não te obriga a estruturar os dados para poder armazená-los.
- É aí que nasce o problema

Boas Práticas

Porque é tão fácil bagunçar um conjunto de dados no Excel

Metainformação implícita ao invés de explícita

1. Metainformação na forma de pistas visuais

- uso de cores
 - fontes, negrito, itálico
 - etc.
 - nada disso é processado por um programa de importação de dados
2. Armazene metainformação em forma textual explícita
- Isso permitirá que ela seja processada pelo seu programa de importação

Boas Práticas

Porque é tão fácil bagunçar um conjunto de dados no Excel

Variáveis Primárias e Variáveis Derivadas

- Variáveis derivadas criadas com *fórmulas* do Excel
- Problemas:
 - mais metainformação não processada pelo seu programa de importação de dados
 - multiplicação de fórmulas = mais chances de erro
 - * O Demônio do *Clica-e-Arrasta*
 - * O Demônio do *Copy-Paste*

Boas Práticas

Porque é tão fácil bagunçar um conjunto de dados no Excel

Variáveis Primárias e Variáveis Derivadas

- Solução:
 - armazene na sua planilha Excel exclusivamente as variáveis primárias
 - deixe para calcular todas as variáveis derivadas no seu programa

Boas Práticas

Vetorização

Para evitar *loops* explícitos, pois *loops* explícitos são geralmente:

1. mais lentos em R,
2. mais sujeitos a erros e
3. menos legíveis

Boas Práticas

Loops explícitos são menos legíveis

Loop explícito

```
for (i in 1:10) {  
  y[i] <- x[i] + 1  
}
```

Versão vetorizada

```
y <- x + 1
```

Boas Práticas

Loops explícitos são mais sujeitos a erros

Queria ter escrito

```
for (i in 1:10) {  
  y[i] <- x[i] + 1  
}
```

mas acabou escrevendo

```
for (i in 1:100) {  
  y[i] <- x[i] + 1  
}
```

Boas Práticas

Loops explícitos são mais sujeitos a erros

Queria ter escrito

```
for (i in 1:10) {  
  y[i] <- x[i] + 1  
}
```

mas acabou escrevendo

```
for (i in 1:10) {  
  y[i] <- x[j] + 1  
}
```

Boas Práticas

Loops explícitos são mais sujeitos a erros

Queria ter escrito

```
for (i in 2:10) {  
  y[i] <- x[i-1]  
}
```

mas acabou escrevendo

```
for (i in 1:10) {  
  y[i] <- x[i-1]  
}
```

Boas Práticas

Loops explícitos são mais sujeitos a erros

Queria ter escrito

```
for (i in 2:10) {  
  y[i] <- x[i-1]  
}
```

mas acabou escrevendo

```
for (i in 2:10) {  
  y[i] <- x[i-10]  
}
```

Integrando Conjuntos de Dados

Integrando Conjuntos de Dados

A integração de dois ou mais conjuntos de dados envolve um grau de complexidade maior do que a organização de um conjunto de dados individual.

Integrando Conjuntos de Dados

O grau de complexidade pode variar

- simplesmente juntar em um conjunto de dados unificado as observações (linhas) de conjuntos de dados que tenham exatamente as mesmas variáveis (colunas)
 - caso mais simples
- realizar agregações em níveis diferentes em cada conjunto de dados até que todos os conjuntos de dados tenham observações (linhas) associáveis entre si
 - caso bem menos simples

Integrando Conjuntos de Dados

Sugestão

Se você tem pouca experiência:

- Passe essa atividade para alguém que já saiba fazer isso
- **OU**
- Reserve um bocado de tempo para aprender a fazer isso direito.